

1 Distribuições condicionais completas e implementação Gibbs

Considere $\mathbf{p} = [p_1, \dots, p_{14}]^\top$, $\mathbf{x} = [n_1, \dots, n_{14}, m_1, \dots, m_{14}]^\top$ e $\mathbb{B} = \{0, 1, 2, \dots, N\}$, temos que a verosimilhança e as distribuições a priori são dadas por

$$\mathcal{L}(N, \mathbf{p}|\mathbf{x}) \propto \frac{N!}{(N-r)!} \prod_{i=1}^{14} p_i^{n_i} (1-p_i)^{N-n_i} \mathbb{I}(N \in \mathbb{N}) \mathbb{I}(p_i \in [0, 1]) \mathbb{I}(r \in \mathbb{B}) \quad (1)$$

$$\pi(N) = \frac{e^{-\lambda} \lambda^N}{N!} \mathbb{I}(N \in \mathbb{N}) \quad (2)$$

$$\pi(p_i) = \mathbb{I}(p_i \in [0, 1]), i = 1, 2, \dots, 14. \quad (3)$$

A seguir vamos derivar a distribuição condicional completa de $N|\mathbf{p}, \mathbf{x}$. Note que $\mathbb{I}(N \in \mathbb{N}) \mathbb{I}(p_i \in [0, 1]) \mathbb{I}(r \in \mathbb{B}) = \mathbb{I}(N \in r, r+1, \dots) \mathbb{I}(p_i \in [0, 1])$, pois $\mathbb{I}(r \in \mathbb{B}) = \mathbb{I}(N \in \{r, r+1, \dots\})$.

$$\begin{aligned} \pi(N|\mathbf{p}, \mathbf{x}) &\propto \mathcal{L}(N, \mathbf{p}|\mathbf{x}) \pi(N) \\ &= \frac{N!}{(N-r)!} \prod_{i=1}^{14} p_i^{n_i} (1-p_i)^{N-n_i} \mathbb{I}(N \in \{r, r+1, \dots\}) \mathbb{I}(p_i \in [0, 1]) \frac{e^{-\lambda} \lambda^N}{N!} \mathbb{I}(N \in \mathbb{N}) \\ &= \frac{e^{-\lambda} \lambda^N}{(N-r)!} \prod_{i=1}^{14} p_i^{n_i} (1-p_i)^N (1-p_i)^{-n_i} \mathbb{I}(N \in \{r, r+1, \dots\}) \mathbb{I}(p_i \in [0, 1]) \\ &= \frac{e^{-\lambda} \lambda^N}{(N-r)!} \prod_{i=1}^{14} [p_i^{n_i}] \prod_{i=1}^{14} [(1-p_i)^N] \prod_{i=1}^{14} [(1-p_i)^{-n_i}] \mathbb{I}(N \in \{r, r+1, \dots\}) \mathbb{I}(p_i \in [0, 1]) \\ &\propto \frac{e^{-\lambda} \lambda^N}{(N-r)!} \left[\prod_{i=1}^{14} (1-p_i) \right]^N \mathbb{I}(N \in \{r, r+1, \dots\}) \mathbb{I}(p_i \in [0, 1]) \\ &= \frac{e^{-\lambda} [\lambda \prod_{i=1}^{14} (1-p_i)]^N}{(N-r)!} \mathbb{I}(N \in \{r, r+1, \dots\}) \mathbb{I}(p_i \in [0, 1]) \frac{e^{-\lambda \prod_{i=1}^{14} (1-p_i)}}{e^{-\lambda \prod_{i=1}^{14} (1-p_i)}} \\ &\propto \frac{\exp\{-\lambda \prod_{i=1}^{14} (1-p_i)\} [\lambda \prod_{i=1}^{14} (1-p_i)]^N}{(N-r)!} \mathbb{I}(N \in \{r, r+1, \dots\}) \mathbb{I}(p_i \in [0, 1]) \\ &\propto \frac{\exp\{-\lambda \prod_{i=1}^{14} (1-p_i)\} [\lambda \prod_{i=1}^{14} (1-p_i)]^{N-r}}{(N-r)!} \mathbb{I}(N \in \{r, r+1, \dots\}) \mathbb{I}(p_i \in [0, 1]) \\ &= \frac{\exp\{-\lambda \prod_{i=1}^{14} (1-p_i)\} [\lambda \prod_{i=1}^{14} (1-p_i)]^{N-r}}{(N-r)!} \mathbb{I}(N-r \in \mathbb{N}) \mathbb{I}(p_i \in [0, 1]) \end{aligned}$$

Portanto

$$\pi(N|\mathbf{p}, \mathbf{x}) \propto \frac{\exp\{-\lambda \prod_{i=1}^{14} (1-p_i)\} [\lambda \prod_{i=1}^{14} (1-p_i)]^{N-r}}{(N-r)!} \mathbb{I}(N-r \in \mathbb{N}) \mathbb{I}(p_i \in [0, 1]) \quad (4)$$

Temos que $(N-r)|(\mathbf{p}, \mathbf{x}) \sim \text{Poisson}(\lambda \prod_{i=1}^{14} (1-p_i))$, identificado pelo *kernel* apresentado em 4.

Agora vamos derivar a distribuição condicional completa de $p_i|N, \mathbf{x}, i = 1, 2, \dots, 14$. Considere $\mathbf{p}_{(i)} = (p_1, p_2, \dots, p_{i-1}, p_{i+1}, \dots, p_{14})$, isto é, o vetor de parâmetros \mathbf{p} sem o i -ésimo elemento.

$$\begin{aligned}
 \pi(p_i|N, \mathbf{p}_{(i)}, \mathbf{x}) &\propto \mathcal{L}(N, \mathbf{p}|\mathbf{x})\pi(\mathbf{p}_{(i)}) \\
 &= \frac{N!}{(N-r)!} \prod_{l=1}^{14} p_l^{n_l} (1-p_l)^{N-n_l} \mathbb{I}(N \in \{r, r+1, \dots\}) \mathbb{I}(p_l \in [0, 1]) \left[\prod_{j \neq i} \mathbb{I}(p_j \in [0, 1]) \right] \\
 &= \frac{N!}{(N-r)!} \prod_{l=1}^{14} p_l^{n_l} (1-p_l)^{N-n_l} \mathbb{I}(N \in \{r, r+1, \dots\}) \mathbb{I}(p_l \in [0, 1]) \\
 &\propto p_i^{n_i} (1-p_i)^{N-n_i} \mathbb{I}(p_i \in [0, 1]) \\
 &= p_i^{(n_i-1)+1} (1-p_i)^{(N-n_i-1)+1} \mathbb{I}(p_i \in [0, 1])
 \end{aligned}$$

Podemos então identificar que $p_i|N, \mathbf{x} \sim \text{Beta}(n_i + 1, N - n_i + 1), i = 1, 2, \dots, 14$ pelo kernel que apresentado acima. Chegamos a conclusão que

$$(N-r)|(\mathbf{p}, \mathbf{x}) \sim \text{Poisson}(\lambda \prod_{i=1}^{14} (1-p_i)) \quad (5)$$

$$p_i|N, \mathbf{x} \sim \text{Beta}(n_i + 1, N - n_i + 1), i = 1, 2, \dots, 14 \quad (6)$$

Para avaliar a convergência para a distribuição estacionária, vamos gerar as 4 cadeias com diferentes pontos iniciais e avaliar visualmente se elas se misturam.

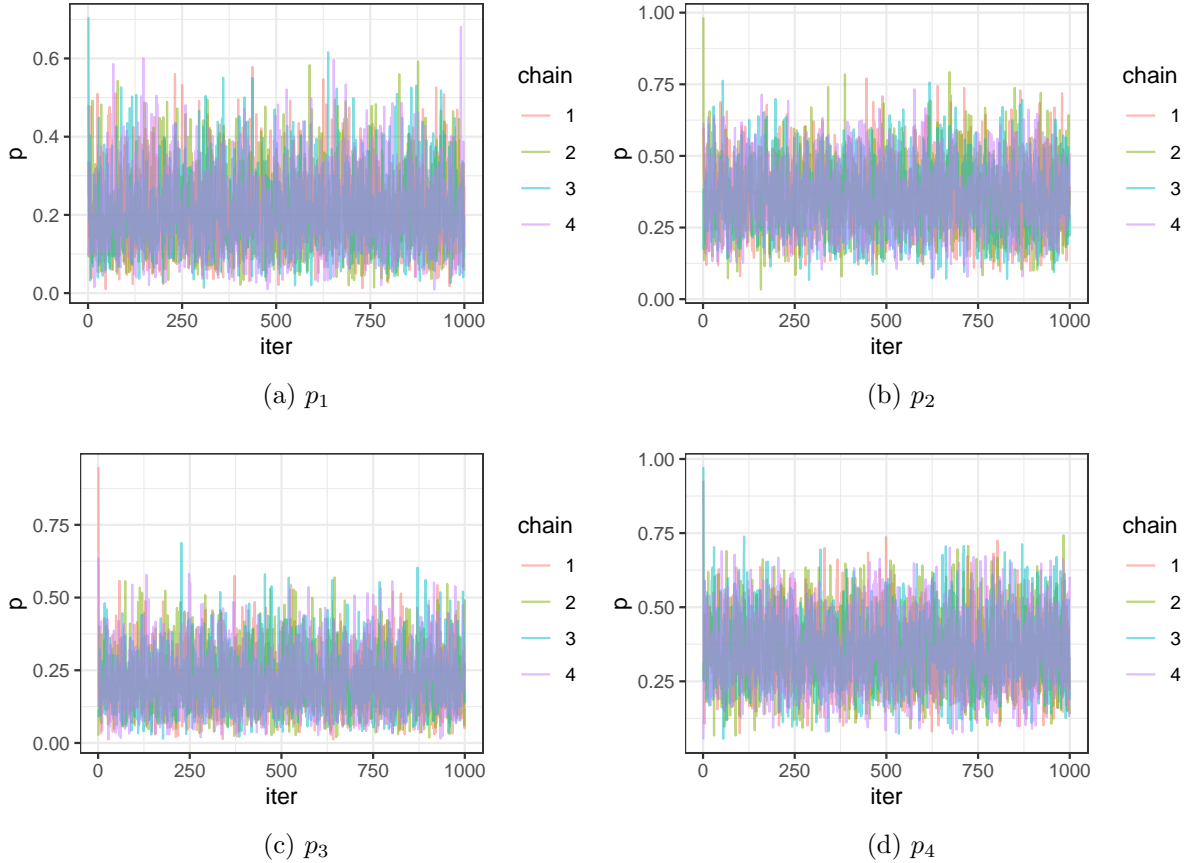


Figura 1:

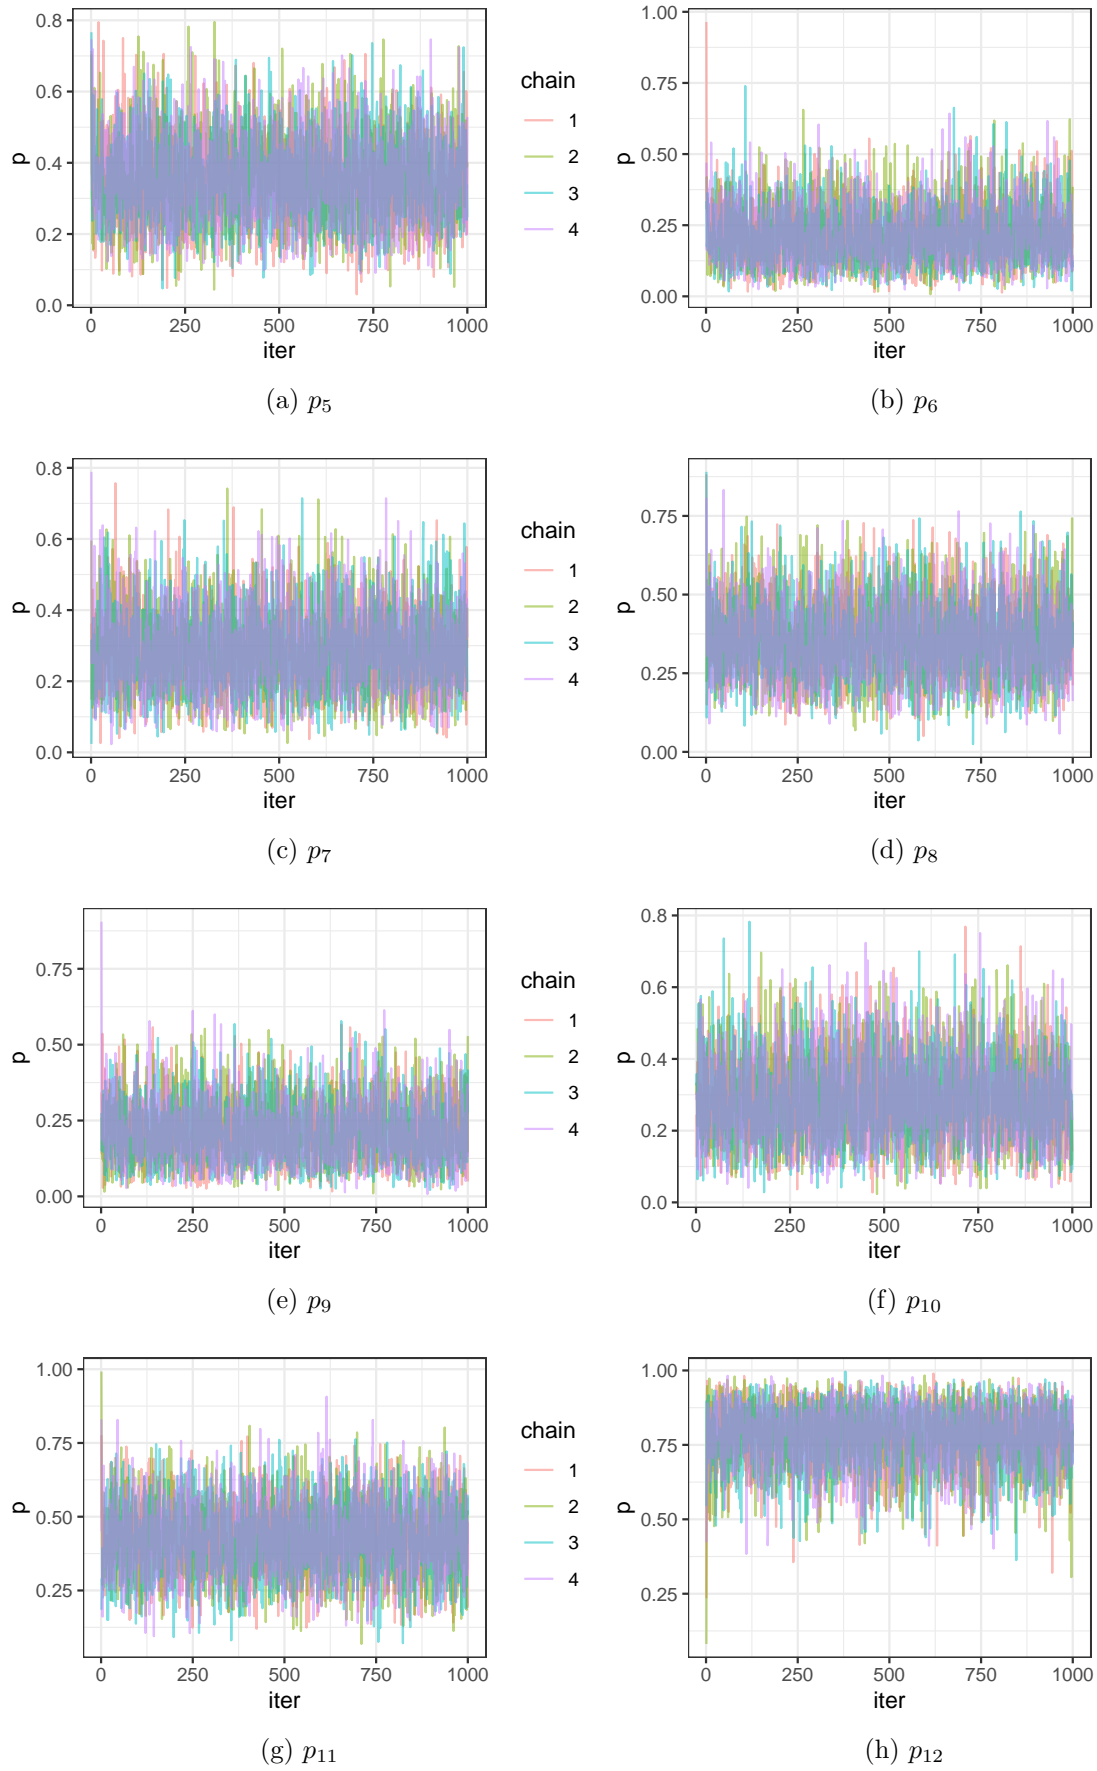


Figura 2:

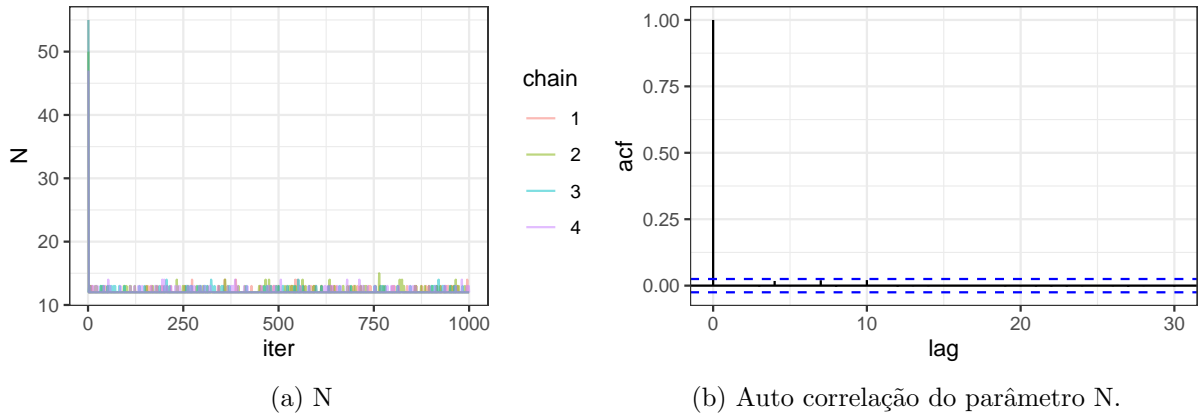


Figura 3:

Podemos ver que as cadeias para todos os parâmetros se misturaram, trazendo indícios da convergência para a distribuição estacionária. Além disso vemos pelo gráfico da autocorrelação da cadeia do parâmetro N que não precisamos realizar o processo de *decorrelation* para garantir uma amostra pseudo-independente. Os gráficos de autocorrelação dos parâmetros $p_i, i = 1, 2, \dots, 14$. apresentaram um comportamento similar.

Parâmetro	Média	Mediana	intervalo de credibilidade 95%
N	12.140	12.000	[12;13]
p1	0.211	0.196	[0.051;0.452]
p2	0.352	0.346	[0.136;0.608]
p3	0.212	0.197	[0.052;0.446]
p4	0.355	0.348	[0.139;0.604]
p5	0.356	0.349	[0.139;0.613]
p6	0.213	0.199	[0.05;0.456]
p7	0.284	0.277	[0.088;0.531]
p8	0.356	0.347	[0.137;0.614]
p9	0.214	0.200	[0.051;0.452]
p10	0.285	0.276	[0.091;0.531]
p11	0.426	0.419	[0.187;0.684]
p12	0.778	0.791	[0.538;0.946]
p13	0.213	0.199	[0.051;0.458]
p14	0.427	0.425	[0.188;0.678]

2 Implementação *Hamiltonian Monte Carlo*

Como bem sabemos, o HMC *sampler* não comporta suportes discretos pelo fato de que a função que descreve a energia cinética há de ser derivável em relação a "trajetória" da cadeia. Por esse fato, optei por procurar uma solução na própria documentação do stan e acabei encontrando a opção de marginalização do parâmetro discreto.

Para realizar a implementação no R, procurei artigos na web que tratassem desse assunto e encontrei uma extensão do HMC chamado de *Discontinuous Hamiltonian Monte Carlo* (NISHIMURA; DUNSON; LU, 2020). Nele é discutido também o porquê o HMC falha quando temos interesse em densidades alvo descontínuas, resumidamente a etapa da solução das equações diferenciais via *leapfrog* apresenta uma instabilidade levando ao erro.

Outra ideia que tive foi utilizar a aproximação da distribuição poisson pela Normal, da seguinte maneira $Poisson(\lambda) \approx Normal(\mu = \lambda, \sigma^2 = \lambda)$. Como essa última foi a solução mais simples que achei, vou implementar primeiro e se tiver tempo hábil tentarei implementar as outras.

2.1 HMC via aproximação Poisson-Normal

No gráfico a seguir podemos ver que a aproximação é realmente razoável.




Figura 4: Aproximação da distribuição $Poisson(\lambda = 50)$ pela distribuição $Normal(\mu = 50, \sigma^2 = 50)$.

A partir da verossimilhança apresentada em 1 e as distribuições a priori $\pi(N) \sim Normal(50, 50)$ e $\pi(p_i) \sim U(0, 1)$, $i = 1, 2, \dots, 14$. Obtemos a seguinte função proporcional a distribuição a posteriori.

$$\pi(N, \mathbf{p}|\mathbf{x}) \propto \left[\frac{N!}{(N-r)!} \prod_{i=1}^{14} p_i^{n_i} (1-p_i)^{N-n_i} \mathbb{I}(p_i \in [0, 1]) \mathbb{I}(r \in [0, N]) \right] \times \pi(N) \times \pi(\mathbf{p})$$

Precisamos então das quantidades referentes a "força cinética" $K(\boldsymbol{\rho})$ e "força potencial" $U(\mathbf{y})$. Definimos

$$U(\mathbf{y}) = -\log(\pi(N, \mathbf{p}|\mathbf{x})) - \left[\log(\Gamma(N+1)) - \log(\Gamma(N-r+1)) + \sum_{i=1}^{14} n_i \log(p_i) + (N-n_i) \log(1-p_i) \right]$$

$$K(\boldsymbol{\rho}) = -\log(\pi(\boldsymbol{\rho}|N, \mathbf{p}))$$

3 Implementação *Hamiltonian Monte Carlo* no STAN

Consegui fazer a implementação do modelo de captura-marcação-recaptura no STAN com as prioris de interesse usando a aproximação da poisson-Normal sugerida anteriormente. A seguir são apresentados os resultados, notamos que foram coerente com os métodos implementados no R.

Referências

NISHIMURA, A.; DUNSON, D. B.; LU, J. Discontinuous hamiltonian monte carlo for discrete parameters and discontinuous likelihoods. *Biometrika*, Oxford University Press, v. 107, n. 2, p. 365–380, 2020.

Apêndice A

A.1 Implementação Gibbs Sampler

```

1 library(readr)
2 library(tidyverse)
3 dados <- read_table("./Atividade1/resolucao/dados.txt",
4                     col_names = FALSE)
5 colnames(dados) <- c('onca', paste0('armadilha', 1:14))
6 nj <- dados%>%
7   pivot_longer(~onca, values_to = "capturada",
8               names_to = "armadilha", names_prefix = 'armadilha',
9               names_transform = list(armadilha = as.numeric))%>%
10  group_by(armadilha)%>%
11  summarise(nj=sum(capturada))
12 mj <- dados%>%
13   pivot_longer(~onca, values_to = "capturada", names_to = "armadilha",
14               names_prefix = 'armadilha',
15               names_transform = list(armadilha = as.numeric))%>%
16  group_by(onca)%>%
17  mutate(mj=case_when(cumsum(capturada)*capturada>1 ~ 1, TRUE ~ 0))%>%
18  group_by(armadilha)%>%
19  summarise(mj=sum(mj))
20 Ngibbs=10e4
21 iter0 <- c(rpois(1,50), runif(14))
22 chain <- matrix(0, ncol = Ngibbs, nrow=length(iter0))
23 chain[,1] <- iter0
24 rownames(chain) <- c("N", paste0("p", 1:14))
25 lambda=50
26 r <- sum(nj$nj)-sum(mj$mj)
27 nj <- nj$nj
28 for (i in 2:Ngibbs) {
29   lambda_pos <- lambda * prod(1-chain[-1,i-1])
30   N_i_plus_1 <- rpois(n=1, lambda = lambda_pos) + r
31   chain[1,i] <- N_i_plus_1
32   for (j in 1:length(nj)) {
33     aux <- rbeta(n = 1, shape1 = nj[j]+1, shape2 = N_i_plus_1-nj[j]+1)
34     chain[j+1,i] <- aux
35   }
36 }

```


A.1 Implementação STAN

```
1 data{
2   int j;
3   vector[j] ni;
4   vector[j] mi;
5 }
6 transformed data{
7   real r;
8   r = sum(ni) - sum(mi);
9 }
10 parameters{
11   vector<lower=0.00001,upper=.9999>[j] p;
12   real<lower=r> N;
13 }
14
15 transformed parameters{
16   real Nt;
17   Nt= N-r;
18 }
19
20 model{
21   target+= normal_lpdf(Nt|50,sqrt(50));
22   target+=uniform_lpdf(p|0,1);
23   target += log(tgamma(N+1)) - log(tgamma(N - r + 1)) + sum(ni .* log(p) + (N-ni) .* log(1-p));
24 }
```